

机器学习基础讲义


① 概念引入

机器学习要解决的核心问题是：**如何让计算机自动从数据中学习规律，而不是依靠人工编写规则**。传统编程中，我们需要为每一种情况手动编写判断逻辑，例如“如果温度高于30度，则开启空调”。但现实世界的问题往往复杂多变，比如识别一张图片里是猫还是狗，我们很难写出一个万能的规则集。机器学习正是为此而生——它让计算机通过分析大量数据，自己“悟”出其中的模式。

直觉类比：想象你是一位老师，要教会一个学生（模型）做数学题。你可以给他带标准答案的练习题（监督学习），让他做完后对照答案，错了就改正；也可以给他一堆没有答案的题目，让他自己整理出题型分类（无监督学习）；还可以让他通过不断尝试和获得反馈（强化学习）来学会解题策略。机器学习正是模仿了这种学习过程。

机器学习主要分为三大范式：

- **监督学习：**使用带标签的数据训练模型，就像学生做带标准答案的练习题。模型给出预测，与标准答案对照，错了就修正。
- **无监督学习：**从无标签数据中发现结构，像在没有答案的情况下自己整理笔记。
- **强化学习：**让智能体在与环境的交互中通过奖励信号学习策略。



图片来源: [Wikimedia Commons](#) (CC BY-SA 4.0)

② 核心原理




图: 「机器学习基础」核心结构 / 流程示意 (系统生成图解)

特征与损失

特征是模型观察世界的窗口。在机器学习中，我们通常用一组数值来描述一个样本，这些数值就是特征。例如，预测房价时，房屋的面积、卧室数量、地理位置等就是特征。**特征工程**指从原始数据中构造、选择对预测有用的输入变量，特征的质量往往比模型的选择更能决定效果上限。

损失函数衡量预测与真实目标的差距，是模型优化的方向盘。训练过程就是不断调整参数让损失变小。常见的损失函数包括：

- **均方误差 (MSE)**：用于回归任务，计算预测值与真实值之差的平方的平均值。
- **交叉熵**：用于分类任务，衡量预测概率分布与真实标签分布之间的差异。

监督学习与无监督学习

监督学习的典型任务包括：

- **分类**：预测离散的类别标签，例如判断一封邮件是否为垃圾邮件、识别图片中的物体类别。
- **回归**：预测连续的数值，例如预测房价或气温。

无监督学习的典型任务包括：

- **聚类**：把相似的样本自动分组，例如把用户按行为习惯分群。
- **降维**：在尽量保留信息的前提下压缩特征维度，便于可视化与后续建模。

过拟合与正则化

过拟合是指模型在训练数据上表现很好，但在新数据上表现很差。这就像学生死记硬背了练习题的答案，但遇到新题型就不会做了。过拟合通常发生在模型过于复杂（参数过多）或训练数据不足时。

正则化是防止过拟合的常用技术。它通过在损失函数中加入一个惩罚项，限制模型参数的大小，从而迫使模型学习更简单的模式。常见的正则化方法包括L1正则化和L2正则化。

关键公式（以线性回归为例）：

- 均方误差损失： $L = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$
- 带L2正则化的损失： $L = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^m w_j^2$ 其中 y_i 是真实值， $\hat{y}_i$ 是预测值， w_j 是模型参数， λ 是正则化强度。

③ 具体例子

监督学习例子：垃圾邮件分类

- **输入特征**：邮件中是否包含“免费”、“中奖”等关键词（二值特征），邮件长度，发件人域名等。
- **输出**：二分类标签（垃圾邮件/非垃圾邮件）。
- **损失函数**：交叉熵。如果模型预测某封邮件是垃圾邮件的概率为0.9，而实际标签是1（垃圾邮件），则损失较小；如果预测概率为0.1，则损失很大。

无监督学习例子：用户分群

- **输入特征**：用户的购买频率、平均消费金额、浏览时长等。
- **输出**：聚类后的群组编号（如“高消费活跃用户”、“低消费沉默用户”等）。

- **过程**：模型自动发现哪些用户的行为模式相似，并将它们归为一类，无需人工标注。

过拟合例子：房价预测

假设我们只有10个房屋样本，但使用了10次多项式回归（模型非常复杂）。模型会完美拟合所有训练样本，但用它预测新房屋的价格时，结果会非常离谱。这就是过拟合。加入L2正则化后，模型会倾向于使用更简单的曲线（如二次或线性），虽然训练误差可能稍大，但泛化能力更强。

④ 代码示例

以下是一个使用Python和scikit-learn库的简单线性回归示例，演示了特征、损失和正则化的基本概念。

```
# 导入必要的库
import numpy as np
from sklearn.linear_model import LinearRegression, Ridge
from sklearn.metrics import mean_squared_error

# 输入：生成模拟数据
# 假设我们有一个特征 x 和目标 y, y 与 x 有线性关系并加入噪声
np.random.seed(42)
X = np.random.rand(100, 1) * 10 # 100个样本, 1个特征, 值在0-10之间
y = 2 * X + 1 + np.random.randn(100, 1) * 2 # 真实关系: y = 2x + 1 + 噪声

# 输出：训练一个线性回归模型（无正则化）
model = LinearRegression()
model.fit(X, y)
y_pred = model.predict(X)
loss = mean_squared_error(y, y_pred)
print(f"无正则化模型 - 均方误差: {loss:.4f}")
print(f"模型参数: 斜率={model.coef_[0][0]:.4f}, 截距={model.intercept_[0]:.4f}")

# 输出：训练一个带L2正则化的岭回归模型（Ridge）
ridge_model = Ridge(alpha=1.0) # alpha是正则化强度λ
ridge_model.fit(X, y)
y_pred_ridge = ridge_model.predict(X)
loss_ridge = mean_squared_error(y, y_pred_ridge)
print(f"带正则化模型 - 均方误差: {loss_ridge:.4f}")
print(f"模型参数: 斜率={ridge_model.coef_[0][0]:.4f}, 截距={ridge_model.intercept_[0]:.4f}")

# 输出说明：
# 无正则化模型会尽量拟合所有数据点，参数可能较大。
# 带正则化的模型会惩罚大参数，因此斜率可能更小，但泛化能力更强。
```

⑤ 常见误区

1. **特征越多越好**：实际上，特征质量比数量更重要。冗余或无关特征会增加模型复杂度，导致过拟合。特征工程的核心是选择对预测有用的输入变量。
2. **训练误差越小，模型越好**：这是过拟合的典型表现。模型可能在训练集上完美拟合，但在测试集上表现很差。应该监控训练曲线，判断是否欠拟合或过拟合。
3. **正则化强度越大越好**：正则化强度（如 λ ）过大，会导致模型过于简单，无法捕捉数据中的规律（欠拟合）。通常需要调参找到合适的平衡点。
4. **所有问题都用监督学习**：当没有标签数据时，无监督学习（如聚类、降维）是更好的选择。例如，用户分群、异常检测等场景。
5. **学习率固定不变**：通常先用学习率扫描找到合适量级，再叠加调度与正则。批大小、学习率与训练轮数需要联合调整。

⑥ 小结

本讲义覆盖了机器学习的基础核心概念：

- **监督学习**：使用带标签数据，解决分类和回归问题。损失函数（如均方误差、交叉熵）是优化的方向盘。
- **无监督学习**：从无标签数据中发现结构，典型任务包括聚类和降维。
- **特征**：模型观察世界的窗口，特征质量决定效果上限。
- **损失函数**：衡量预测与真实的差距，训练过程就是最小化损失。
- **过拟合**：模型在训练集上表现好但泛化差，通常由模型复杂或数据不足引起。
- **正则化**：通过惩罚大参数防止过拟合，常用L1和L2正则化。

这些概念是机器学习的基石，理解它们有助于后续学习更复杂的模型（如神经网络、大语言模型）和技术（如迁移学习、参数高效微调）。

<!-- media:enriched -->